

Proibida a reprodução e comercialização sem autorização

Usuário: Julio Cesar Justini dornellas, julio.justini@gmail.com, CPF: 05536778960


Box Plot e Outliers

O box-plot é uma representação gráfica que nos dá uma noção da distribuição dos dados.

Considere o seguinte conjunto.

{5; 5; 5,6; 5,8; 6,2; 6,5; 6,6; 7; 7; 8; 9; 10; 10; 11; 12; 22}

Por enquanto não vou explicar como se constrói o box-plot, isso será feito mais abaixo. Apenas adianto que, para este conjunto, o box-plot fica assim:




Agora que vimos a "cara" do box-plot, vamos entender exatamente como ele é desenhado, e o que ele representa.

De forma bem direta, vemos que ele tem duas partes:

- um retângulo
- duas "pernas" que saem do retângulo

O retângulo indica os **quartis**.



Assim, da figura acima, temos que os quartis são:

$$Q_1 = 6$$

$$Q_2 = 7$$

$$Q_3 = 10$$

Se você checar nosso conjunto de dados (5; 5; 5,6; 5,8; 6,2; 6,5; 6,6; 7; 7; 8; 9; 10; 10; 11; 12; 22) observará que é exatamente isso: o primeiro quartil vale 6, o segundo vale 7 e o terceiro vale 10.

A amplitude interquartílica, dada pela diferença entre o primeiro e o terceiro quartil, fica:

$$d = Q_3 - Q_1$$

$$d = 10 - 6 = 4$$

Essa distância é importante para entendermos as perninhas do box-plot. As "perninhas" são as linhas que saem do retângulo.

A linha de cima vai até a observação mais alta existente. Só que tem um detalhe. Esta linha não pode ultrapassar o limite estabelecido por:

$$Q_3 + 1,5d$$

Ou seja, o tamanho máximo da linha é igual a 1,5 vezes a amplitude interquartílica.

Como a amplitude interquartílica é igual a 4, o tamanho máximo da linha é igual a 6. Logo, a linha pode ir, no máximo, até:

$$Q_3 + 1,5d = 10 + 6 = 16$$

A linha pode ir até 16. Logo, a linha não vai poder indicar o maior valor de todos (=22). O efeito disso é que o valor 22 é considerado atípico, ou ainda, um “*outlier*”. Todas as observações que ficarem fora do limite das linhas são consideradas atípicas.


Bom, excluindo-se os valores atípicos, a maior observação que sobra é o 12. Por isso a linha de cima vai até 12.

Para a linha de baixo é a mesma coisa. Ela começa no primeiro quartil e desce. Mas ela tem um limite de tamanho. Seu tamanho máximo é de $1,5d$. Assim, ela vai até:


$$Q_1 - 1,5d = 6 - 6 = 0$$

Todos os valores abaixo de zero são tidos como atípicos. No caso, não há nenhum valor abaixo de zero que possa ser considerado outlier.

Deste modo, a linha de baixo pode ir até 5, que é a menor observação.



Por fim, se quisermos indicar a existência do *outlier*, que está além do tamanho máximo da perna superior, podemos indicar isso com um asterisco.




Pronto, com isso estudamos todos os elementos do Box-Plot.

Vejam que partimos de um conjunto de dados e montamos o Box-plot. Mas **não** dá para fazer o caminho contrário. **Não** dá para partir do box-plot e saber qual o conjunto de dados original.

Vamos praticar com algumas questões de prova:

(Fundação Universa - CEB)

Considere o gráfico Boxplot seguinte:



O valor marcado com um asterisco (*) representa

- (A) o menor valor;
- (B) $1,5 \times (Q_3 - Q_1)$
- (C) $Q_1 - 1,5 \times (Q_3 - Q_1)$
- (D) $(Q_3 - Q_1)$
- (E) um outlier.

Resolução.

Asteriscos são usados para indicar a existência de outliers. Eles são alocados fora dos limites definidos por $Q_1 - 1,5d$ e $Q_3 + 1,5d$.

Gabarito: E

(Cespe - INMETRO)

Nos últimos cinco meses, uma família apresentou o seguinte quadro de despesas:

- 1.º mês: R\$ 1.000,00;
- 2.º mês: R\$ 1.200,00;
- 3.º mês: R\$ 900,00;
- 4.º mês: R\$ 1.100,00;
- 5.º mês: R\$ 800,00.

Em relação a esse conjunto de dados, assinale a opção correta.

- A) O desvio padrão amostral é superior a R\$ 200,00.
- B) O primeiro quartil é igual a R\$ 1.100,00.
- C) O terceiro quartil é igual a R\$ 1.200,00.
- D) Ao se construir um Box plot para esse conjunto de dados, os limites inferior e superior estarão contidos no intervalo [R\$ 400,00, R\$ 1.600,00].
- E) A média é maior que a mediana dos dados.

Resolução:

Vamos direto para a alternativa que trata de Box-plot.

Rol:

800, 900, 1.000, 1.100, 1.200

A mediana é o termo do meio:

$$D = 1.000$$

A mediana divide o conjunto de dados em duas partes com 2 elementos cada.

800, 900	1.100, 1.200
----------	--------------

O primeiro quartil é a mediana da primeira parte.

$$Q_1 = \frac{800+900}{2}$$

$$Q_1 = 850$$

O terceiro quartil é a mediana da segunda parte.

$$Q_3 = \frac{1.100+1.200}{2} = 1.150$$

O intervalo interquartil é igual a:

$$d = Q_3 - Q_1 = 1.150 - 850 = 300$$

Os limites do Box plot são:

$$\text{- Limite inferior: } Q_1 - 1,5d = 850 - 1,5 \times 300 = 400$$

$$\text{- Limite superior: } Q_3 + 1,5d = 1.150 + 1,5 \times 300 = 1.600$$

Os limites do Box-plot são 400 e 1.600. A alternativa D está correta.

Gabarito: D

Agora vejamos as demais alternativas.

A letra “a” é a de verificação mais demorada, pois depende de uma maior quantidade de cálculos. Na hora da prova, o ideal é marcá-la “por exclusão”.

Letra B: Já vimos que o primeiro quartil é 850. **Alternativa errada.**

Letra C: Já vimos que o terceiro quartil é 1.150. **Alternativa errada.**

Letra E:

$$\overline{X} = \frac{800+900+1.000+1.100+1.200}{5} = 1.000$$

A média é igual à mediana. Alternativa errada.

Finalmente, para analisar a letra “a”, vamos criar a variável auxiliar:

$$d = \frac{x-1.000}{100}$$

Os valores de “d” são:

$$-2, -1, 0, 1, 2$$

Logo:

$$\overline{d} = \frac{-2-1+0+1+2}{5} = 0$$

$$\overline{d^2} = \frac{4+1+0+1+4}{5} = 2$$

$$\sigma_d^2 = \overline{d^2} - \overline{d}^2 = 2 - 0 = 2$$

$$\sigma_d = \sqrt{2}$$

Agora usamos propriedades do desvio padrão:

$$x = 100d + 1.000$$

$$\sigma_x = 100\sigma_d = 100\sqrt{2}$$


O desvio padrão amostral fica:

$$s_x = 100\sqrt{2} \times \frac{5}{4} \approx 100 \times 1,4 \times 1,25 = 175$$

O desvio padrão amostral não é superior a 200. **Alternativa errada.**

Resumo

Relembrando o exemplo dado na parte teórica:



Texto: Professor(a) Vítor Menezes Santana

Proibida a reprodução e comercialização sem autorização

Usuário: Julio Cesar Justini dornellas, julio.justini@gmail.com, CPF: 05536778960
